

### **Zadanie 1**

Zapoznanie się z podstawowymi funkcjami biblioteki sentimentr – slajdy 3-12

### Zadanie 2

Zgodnie z opisem slajd 13

## Biblioteki do analizy sentymentu

R

Sentimentr https://cran.r-project.org/web/packages/sentimentr/

RSentiment https://cran.r-project.org/web/packages/RSentiment/

SentimentAnalysis https://github.com/sfeuerriegel/SentimentAnalysis

## **Python**

Natural Language Toolkit <a href="http://www.nltk.org/">http://www.nltk.org/</a> http://www.nltk.org/</a> https://sourceforge.net/projects/nltk/

http://www.laurentluce.com/posts/twitter-sentiment-analysis-using-python-and-nltk/

http://www.nltk.org/howto/sentiment.html

TextBlob https://textblob.readthedocs.io/en/dev/

**Pomocnicze** 

TwitteR https://www.rdocumentation.org/packages/twitteR/versions/1.1.9

### Bibilioteka sentimentr

Metodę słownika rozszerzonego sentimentr, która może dawać lepsze wyniki niż proste podejście do słownika odnośników, które nie uwzględnia zmian walencyjnych z udziałem modyfikatorów. Algorytm wykorzystuje słownik sentymentów (np. Jockers, (2017)) do oznaczania spolaryzowanych słów. Każdy akapit (pi = {s1, s2,..., sn}) złożony ze zdań jest podzielony na odrębne zdania. Każde zdanie (sj) jest podzielone na uporządkowany zbiór słów. Interpunkcja jest usuwana, z wyjątkiem interpunkcji pauzy (przecinki, dwukropki, średniki), które są uważane za słowo w zdaniu. Słowa w każdym zdaniu (wi, j, k) są wyszukiwane i porównywane ze słownikiem spolaryzowanych słów (np. Połączona i rozszerzona wersja Jockera (2017) Wyrazy dodatnie (wi, j, k +) i ujemne (wi, j, k-) są odpowiednio oznaczone +1 i - 1. Spolaryzowany klaster kontekstu domyślnie przyjmuje 4 słowa przed i dwa słowa po analizowanym słowie, aby uznać je za zmienniki wartościowości.

#### valence shifters

Zmiany wartościowości wpływają na spolaryzowane słowa. W przypadku negatorów i spójników cały sentyment klauzuli może zostać odwrócony lub unieważniony. Jeśli zmiany wartościowości występują dość często, proste wyszukiwanie w słowniku może nie modelować odpowiednio sentymentu.

Zmienne wartościowości współwystępują ze spolaryzowanymi słowami, potencjalnie zmieniając, a nawet odwracając i unieważniając sentyment klauzuli. Poniższa tabela pokazuje współczynnik współwystępowania na poziomie zdania zmienników wartościowości ze słowami spolaryzowanymi w kilku rodzajach tekstów

Negator zamienia znak spolaryzowanego słowa (e.g., "I do not like it.") lexicon::hash\_valence\_shifters[y==1]

Wzmacniacz zwiększa wpływ spolaryzowanego słowa (e.g., "I really like it."). lexicon::hash\_valence\_shifters[y==2]

Osłabiacz zmniejsza wpływ spolaryzowanego słowa (e.g., "I hardly like it."). lexicon::hash\_valence\_shifters[y==3]

Konwersja przestawna zastępuje poprzednią klauzulę zawierającą spolaryzowane słowo(e.g., "I like it but it's not worth it."). lexicon::hash\_valence\_shifters[y==4]

Text	Negator A	Amplifier Dea	amplifier Adv	ersative
Cannon reviews	21%	23%	8%	12%
2012 presidential debate	23%	18%	1%	11%
Trump speeches	12%	14%	3%	10%
Trump tweets	19%	18%	4%	4%
Dylan songs	4%	10%	0%	4%
Austen books	21%	18%	6%	11%
Hamlet	26%	17%	2%	16%

### Podstawowe funkcje

sentiment
sentiment\_by
profanity
profanity\_by
emotion
emotion\_by
uncombine

get\_sentences

replace\_emoji replace\_emoticon replace\_grade

replace\_internet\_slang

replace rating

as\_key is\_key

update\_key highlight

general\_rescale

sentiment\_attribute
validate\_sentiment

Sentiment at the sentence level

Aggregated sentiment by group(s)

Profanity at the sentence level

Aggregated profanity by group(s)

Emotion at the sentence level

Aggregated emotion by group(s)

Extract sentence level sentiment from sentiment\_by

Regex based string to sentence parser (or get sentences from

sentiment/sentiment by)

repalcement

Replace emoticons with word equivalent

Replace grades (e.g., "A+") with word equivalent

replacment

Replace ratings (e.g., "10 out of 10", "3 stars") with word equivalent

Coerce a data.frame lexicon to a polarity hash key

Check if an object is a hash key

Add/remove terms to/from a hash key

Highlight positive/negative sentences as an HTML document

Generalized rescaling function to rescale sentiment scoring

Extract the sentiment based attributes from a text

Validate sentiment score sign against known results

sentiment(text.var, polarity\_dt = lexicon::hash\_sentiment\_jockers\_rinker, valence\_shifters\_dt = lexicon::hash\_valence\_shifters, hyphen = "", amplifier.weight = 0.8, n.before = 5, n.after = 2, question.weight = 1, adversative.weight = 0.25, neutral.nonverb.like = FALSE, missing\_value = 0, ...)

text.var The text variable. Can be a get\_sentences object or a raw character vector though get\_sentences is preferred as it avoids the repeated cost of doing sentence boundary disambiguation every time sentiment is run.

polarity\_dt A data.table of positive/negative words and weights with x and y as column names. The lexicon package has several dictionaries that can be used, including:

- lexicon::hash sentiment jockers rinker
- lexicon::hash\_sentiment\_jockers
- lexicon::emojis\_sentiment
- lexicon::hash\_sentiment\_emojis
- lexicon::hash sentiment huliu
- lexicon::hash sentiment loughran mcdonald
- lexicon::hash sentiment nrc
- lexicon::hash sentiment senticnet
- lexicon::hash sentiment sentiword
- · lexicon::hash sentiment slangsd
- lexicon::hash\_sentiment\_socal\_google

valence\_shifters\_dt - A data.table of valence shifters that can alter a polarized word's meaning and an integer key for negators (1), amplifiers [intensifiers] (2), de-amplifiers [downtoners] (3) and adversative conjunctions (4) with x and y as column names.

hyphen - The character string to replace hyphens with. Default replaces with nothing so 'sugar-free' becomes 'sugarfree'. Setting hyphen = " " would result in a space between words (e.g., 'sugar free'). Typically use either " " or default "".

amplifier.weight The weight to apply to amplifiers/de-amplifiers [intensifiers/downtoners] (values from 0 to 1). This value will multiply the polarized terms by 1 + this value.

n.before The number of words to consider as valence shifters before the polarized word. To consider the entire beginning portion of a sentence use n.before = Inf.

n.after The number of words to consider as valence shifters after the polarized word. To consider the entire ending portion of a sentence use n.after = Inf.

## Analiza sentymentu

#### sentiment\_by(mytext)

3

3

4:

5:


element_id word_count				sd ave_sentiment		
1:	1	10 1	1.497465	-0.8088680		
2:	2	5	NA	0.5813777		
3:	3	90	.284605	0.2196345		

1 5 0.4024922

4 0.0000000

# Zbiór wypowiedzi i emocje

```
p <- presidential debates 2012
View(p)
(out <- with(
                                                                      CROWLEY time
  presidential debates 2012,
                                                                      LEHRER.time
  sentiment by(
     get sentences(dialogue),
                                                                       OBAMA.time
     list(person, time)
                                                                       OBAMA.time 2
))
                                                                      ROMNEY.time
person time word count
                            sd ave_sentiment
    OBAMA time 1
                      35990.2535006
                                      0.12256892
                                                                      ROMNEY.time
    OBAMA time 2
                      74770.2509177 0.11217673
    OBAMA time 3
                                      0.07975688
                      7243 0.2441394
4: ROMNEY time 1
                      4085 0.2525596
                                      0.10151917
    ROMNEY time 2
                      75360.2205169
                                      0.08791018
                                                                      ROMNEY time
    ROMNEY time 3
                      8303 0.2623534
                                      0.09968544
7: CROWLEY time 2
                      1672 0.2181662 0.19455290
8: LEHRER time 1
                     765 0.2973360 0.15473364
                                                                       OBAMA.time
9: QUESTION time 2
                       583 0.1756778 0.03197751
10: SCHIEFFER time 3
                      1445 0.2345187 0.08843478
                                                                      QUESTION time 2
plot(out)
```



#### **Emocje**

```
em <- emotion(p$dialogue)
View(em)
em <- emotion by(p$dialogue,by=list( p$person,p$time))</pre>
```


### Opinie i komentarze

```
install.packages("sentimentr")
library(sentimentr)

install.packages("ndjson")
library(ndjson)

setwd("c:/R_data");

df = stream_in("opinions.json")
head(df)
```



```
sentiment=sentiment(df$reViewText, emotion_dt = lexicon::hash_sentiment_sentiword)

View(sentiment)


library(ggplot2)

qplot(sentiment$sentiment, geom="histogram",binwidth=0.1,main="Histogram")
```

# Opinie i komentarze z grupowaniem

```
install.packages("sentimentr")
library(sentimentr)
install.packages("ndjson")
library(ndjson)
setwd("c:/R data");
df = stream in("opinions.json")
head(df)
sentiment=sentiment by(df$reViewText)
View(sentiment)
element id — The id number of the reView
word count — The word count of the reView
sd — odchylenie standardowe sentymetu dla zdań
ave sentiment — średni sentyment dla zdań w wypowiedzi
summary(sentiment$ave sentiment)
df$ave sentiment=sentiment$ave sentiment
df$sd sentiment=sentiment$sd
library(ggplot2)
```

	□⇒   🔊   🔻 Filter								
_	element_id $^{\scriptsize \scriptsize $	word_count	sd <sup>‡</sup>	${\it ave\_sentiment}  ^{\hat{\neg}}$					
1	1	4	0.500000000	0.3858585042					
2	2	44	0.049484020	0.0919777849					
3	3	29	0.246244375	-0.2007321540					
4	4	262	0.158548937	0.1356085444					
5	5	45	0.217477291	0.3561249613					
6	6	20	0.028093109	0.1966415231					
7	7	32	0.377022094	0.0169661915					
8	8	33	0.298797395	0.0719261063					
9	9	60	0.377336270	-0.3319925269					
10	10	26	0.153960072	0.1301989833					
11	11	4	0.041217521	0.7791451884					
12	12	18	0.319801075	-0.2467959285					
13	13	17	0.506131757	0.1039910178					
14	14	44	0.396479196	0.1036032903					
15	15	8	NA	-0.7247844507					
16	16	33	0.230285141	-0.2836654287					
17	17	15	NA	-0.0129099445					
18	18	63	0.453962302	-0.1889216947					
19	19	2	NA	0.5303300859					
20	20	44	0.177355497	-0.0276925761					
21	21	22	0.199617138	0.3532826659					



qplot(sentiment\$ave\_sentiment, geom="histogram",binwidth=0.1,main="Histogram")

## Budowanie własnego słownika

```
key <- data.frame(
  words = c("cat", "dog", "bunny"),
  polarity = c(1,-1,0),
  stringsAsFactors = FALSE
mykey <- as key(key)
is key(mykey)
sentiment by("cat", polarity dt = mykey)
sentiment by("cat, dog, bunny", polarity dt = mykey)
mykey_new <- update_key(mykey, drop = c("cat"))
sentiment by("cat, dog, bunny", polarity dt = mykey new)
```

### Wizualizacja

```
library(magrittr)
library(dplyr)
set.seed(2)

setwd("c:/R_data");

df = stream_in("opinions.json")
head(df)
```

```
U. V.: -.332
            Too expensive for such poor quality. There was no improvement and I am starting to think my scalp is worse off than it was before I started using this product, I do agree with other reviews that it feels watered down too much. Had to use more shampoo than all other shampoo's I have tried to get a good lather.
            Arrived opened and leaking all over the box. Tried shampoo but didn't help at all. Still so itchy.
Stelling Reed: + 530
             Great Product; does wonders for colored treated hair.
D. Bazinett: +.214
             ff you want your skin moisturized and feeling absolutely great then buy this body cream. Perlier makes such a great line of products. I also buy the bath cream to go with this. It just smells so wonderful and leav
Judy: +.487
            Thank You, I only wish it was more affordable.
Zhenyu Hong: -.544
            the smell is bad and totally not natural for me
susanb1222: +.167
            The price for an Hermes product is the best
jennifer castleman: +.352
            love it... smells so good and was delivered fast.... wrapped in bubble wrap and a nice big box.... buy with confidence
Leslie A. Pritchard: +.321
            This cream smells incredible and has made my skin so soft. Try the coordinating hand cream and massage cream. Love it
Zhenyu Hong: -.544
            the smell is bad and totally not natural for me
susanb1222: +.167
            The price for an Hermes product is the best
jennifer castleman: +.352
```

df %>%
filter(reViewerName %in% sample(unique(reViewerName), 10)) %>%
mutate(reView = get\_sentences(reViewText)) %\$%
sentiment\_by(reView, reViewerName) %>%
highlight()

### **Zadanie 2**

- Pobrać zbiór danych dla dowolnej kategorii produktowej ze strony https://nijianmo.github.io/amazon/index.html
- Wyznaczyć średnie wartości sentymentu dla wartości overal reView 1,2,3,4,5 dla różnych słowników (3) i parametrów valence\_shifters (3) i porównać różnice.
  - 1 avg(sent1)
  - 2 avg(sent2)
  - 3 avg(sent3)
  - 4 avg(sent4)
  - 5 avg(sent5)
- Porównać wartości sentymentu, histogramy dla dwóch wybranych, konkurencyjnych produktów
- Wyznaczyć udział poszczególnych emocji w zbiorze komentarzy dla dwóch wybranych produktów
- Wybrać produkt z dużą liczbą ocen, dokonać podziału na miesiące, lub dni w zależności od liczby ocen i przeanalizować zmiany sentymentu w czasie negative/positive